


Instytut Matematyki Stosowanej

Zespół projektowy: ID-86	1. Patryk Graban - kierownik 2. Błażej Kardynał 3. Bartosz Bycul
Opiekun:	dr inż. Robert Benke
Klient:	dr inż. Marek Strachacki (Intel Technology Poland Sp. z o.o.)
Data zakończenia:	14.06.2024
Słowa kluczowe:	Graph Neural Networks, Pytorch Geometric, Deep Graph Library, Coordinate Matrix, Compressed Sparse Row



TEMAT PROJEKTU:

Porównanie formatów danych w grafowych sieciach neuronowych (GNNs) oraz ich wydajności obliczeniowej w bibliotekach GNN: PyTorch Geometric (PyG) oraz Deep Graph Library (DGL)

TEZA BADAWCZA, CELE I ZAKRES PROJEKTU:

W naszym projekcie będziemy używali pojęcia macierzy rzadkiej, czyli macierzy której większość elementów stanowią elementy zerowe. Macierz będzie rzadka jeśli jej stosunek NNZ (Number of Non Zero) do rozmiaru macierzy będzie mniejszy niż 0.5.

Przechowywanie danych o elementach zerowych jest nieoptymalne, więc będziemy rozważali równe podejścia na przechowywanie tych informacji. W naszym projekcie najbardziej skupimy się na macierzy COO i CSR.

1. Format COO (Coordinate Matrix) - jest prostym i elastycznym sposobem na przechowywanie macierzy rzadkich.
2. Format CSR (Compressed Sparse Row) - jest idealny do pracy z macierzami rzadkimi, szczególnie kiedy często operujemy na wierszach.
3. PyTorch Geometric - Oferuje intuicyjny interfejs do pracy z danymi grafowymi, wspiera różne formaty danych i techniki optymalizacji, takie jak zrównoleglanie obliczeń.
4. Deep Graph Library - Oparta na frameworkach takich jak PyTorch i TensorFlow, również oferuje wsparcie dla różnych formatów danych grafowych i optymalizacji, z naciskiem na skalowalność i wydajność.
5. Message-passing - Trzyetapowy proces przekazywania informacji między węzłami w sieci neuronowej
6. Operacje SCATTER i GATHER - Stanowią one rdzeń mechanizmu przekazywania wiadomości w GNN.

OSIĄGNIĘTE REZULTATY:


Uruchomiliśmy skrypty sieci oparte na modelach GCN (Graph Convolutional Network) i GAT (Graph Attention Network), które opierały się na macierzach rzadkich COO badając dokładność tych modeli na zbiorze danych. Model GCN został również przekonwertowany, żeby obierał się na formacie macierzy CSR, dokonując podobnych testów.

CECHY CHARAKTERYSTYCZNE ROZWIĄZANIA, KIERUNKI DALSZYCH PRAC:

Następnym naszym celem będzie zaimplementowanie MessagePassing na COO i CSR w pythonie przy użyciu zewnętrznej biblioteki oraz pomiar czasu i peak memory usage dla E2E COO/CSR x CPU/GPU x [GCN/GAT/GraphSage/PNA]

Institute of Applied Mathematics

Project team: ID:123 KIOP	1. Patryk Graban - leader 2. Błażej Kardynał 3. Bartosz Bycul
Supervisor:	Robert Benke PhD
Client:	Marek Strachacki (Intel Technology Poland Sp. z o.o.)
Date:	14.06.2024
Key words:	Graph Neural Networks, Pytorch Geometric, Deep Graph Library, Coordinate Matrix, Compressed Sparse Row



PROJECT TITLE:

Comparison of Data Formats in Graph Neural Networks (GNNs) and Their Computational Performance in GNN Libraries: PyTorch Geometric (PyG) and Deep Graph Library (DGL)

RESEARCH THESIS, OBJECTIVES AND SCOPE:

In our project, we will use the concept of a sparse matrix, which is a matrix in which the majority of elements are zero. A matrix is considered sparse if its NNZ (Number of Non-Zero elements) ratio to the total size of the matrix is less than 0.5. Storing data about zero elements is inefficient, so we will consider different approaches to storing this information. In our project, we will focus primarily on the COO and CSR formats.

- 1.CO (Coordinate Matrix) Format** - A simple and flexible way to store sparse matrices.
- 2.CSR (Compressed Sparse Row) Format** - Ideal for working with sparse matrices, especially when operations on rows are frequent.
- 3.PyTorch Geometric** - Offers an intuitive interface for working with graph data, supports various data formats, and optimization techniques such as parallel computation.
- 4.Deep Graph Library** - Based on frameworks like PyTorch and TensorFlow, it also supports various graph data formats and optimizations, with an emphasis on scalability and performance.
- 5.Message-Passing** - A three-step process of exchanging information between nodes in a neural network.
- 6.SCATTER and GATHER Operations** - Form the core mechanism of message passing in GNNs.

RESULTS:

We have run network scripts based on GCN (Graph Convolutional Network) and GAT (Graph Attention Network) models, which relied on COO sparse matrices to examine the accuracy of these models on the dataset. The GCN model was also converted to operate on the CSR matrix format, conducting similar tests.

MAIN FEATURES, FUTURE WORKS:

Our next goal is to implement MessagePassing using COO and CSR in Python with an external library and measure the time and peak memory usage for E2E COO/CSR x CPU/GPU x [GCN/GAT/GraphSage/PNA].